

BAB IV HASIL DAN PEMBAHASAN

4.1 *Data Acquisition*

Data yang digunakan dalam penelitian ini diperoleh dari situs *Kaggle* dalam bentuk dataset harga rumah di Kota Bandung yang dapat diakses melalui tautan berikut ini <https://www.Kaggle.com/datasets/khaleeel347/harga-rumah-seluruh-kecamatan-di-kota-bandung>. Dataset tersebut merupakan hasil web *scraping* pada bulan Maret 2024 dari situs properti rumah123.com dan disediakan dalam format file *Comma-Separated Values* (CSV). Dataset terdiri dari 7.610 data properti dengan 11 fitur. Deskripsi data disajikan pada Tabel 4.1 di bawah ini:

Tabel 4. 1 Deskripsi Data pada Dataset

Fitur	Keterangan	Tipe Data
Tipe	Tipe atau kategori properti	<i>String</i>
Status	Status properti (tersedia, terjual)	<i>String</i>
Harga	Harga properti dalam Rupiah Indonesia	<i>String</i>
Angsuran	Detail rencana angsuran yang terkait dengan properti	<i>String</i>
Nama Rumah	Nama atau judul properti hunian	<i>String</i>
Lokasi	Lokasi atau area di Bandung tempat properti tersebut berada	<i>String</i>
Jumlah Kamar Tidur	Jumlah kamar tidur di properti	<i>Integer</i>

Fitur	Keterangan	Tipe Data
Jumlah Kamar Mandi	Jumlah kamar mandi di properti	<i>Integer</i>
Jumlah Carport	Jumlah carport atau tempat parkir yang tersedia di properti	<i>Integer</i>
Luas Tanah	Luas total tanah properti dalam meter persegi	<i>String</i>
Luas Bangunan	Luas total bangunan properti dalam meter persegi	<i>String</i>

Variabel harga rumah digunakan sebagai variabel target dalam penelitian ini, sedangkan fitur lainnya berperan sebagai fitur prediktor setelah melalui proses seleksi dan transformasi. Pada tahap akuisisi data, dataset dimuat ke dalam lingkungan pemrograman *Python* menggunakan pustaka *pandas* untuk dilakukan pemeriksaan awal terhadap struktur dan kondisi data. Pemeriksaan awal dilakukan untuk mengidentifikasi jumlah baris dan fitur, tipe data setiap fitur, serta kondisi awal data. Hasil pemeriksaan menunjukkan bahwa sebagian besar fitur masih berupa teks (*string*), termasuk harga, lokasi, serta informasi luas bangunan dan luas tanah, sehingga memerlukan proses pembersihan dan konversi ke format numerik pada tahap *preprocessing*.

4.2 Data Preprocessing

Tahap *Data Preprocessing* dilakukan untuk memastikan dataset berada dalam kondisi optimal sebelum digunakan dalam proses pemodelan. Mengingat data diperoleh dari hasil *web scraping*, dataset awal masih mengandung berbagai permasalahan seperti inkonsistensi format, nilai kosong, serta nilai ekstrem yang berpotensi memengaruhi hasil prediksi. Oleh karena itu, *preprocessing* dilakukan secara bertahap untuk meningkatkan kualitas data dan memastikan bahwa data yang digunakan dalam kondisi yang optimal.

a. *Cleaning Data*

Berdasarkan hasil pemeriksaan awal, ditemukan bahwa dataset belum memiliki *header* fitur, beberapa atribut masih tersimpan dalam format teks dan mengandung karakter *non-numerik*. Fitur harga, luas tanah dan luas bangunan awalnya memuat simbol mata uang, satuan, serta format penulisan yang tidak seragam. Setelah dilakukan proses *cleaning*, dataset sudah memiliki *header*, seluruh karakter *non-numerik* berhasil dihilangkan dan fitur tersebut dikonversi ke dalam format numerik. Fitur lokasi mengalami ketidakkonsistenan penulisan, seperti perbedaan spasi, penggunaan huruf besar dan kecil, serta variasi penamaan wilayah. Proses normalisasi teks pada fitur lokasi menghasilkan kategori yang lebih konsisten, sehingga setiap kecamatan atau wilayah hanya direpresentasikan oleh satu bentuk penulisan. Beberapa fitur yang bersifat deskriptif dan tidak memberikan kontribusi langsung terhadap prediksi harga, seperti tipe, status, cicilan, dan judul dihapus dari dataset. Hasil dari tahap ini adalah dataset dengan struktur yang lebih rapi, konsisten, dan siap untuk tahap selanjutnya.

b. *Handling Missing Value*

Setelah proses *cleaning*, dilakukan identifikasi terhadap keberadaan *missing value* pada setiap fitur. Hasil analisis menunjukkan bahwa sebagian data memiliki informasi lengkap, khususnya pada fitur-fitur utama yang berpengaruh langsung terhadap harga rumah. Keberadaan nilai kosong ini dapat mengganggu proses pelatihan model dan menyebabkan hasil prediksi menjadi tidak stabil. Fitur yang memiliki *missing value* ditunjukkan pada Tabel 4.2 berikut:


Tabel 4. 2 Jumlah Missing Value

Fitur	Jumlah Missing Value
Luas Bangunan	2
Luas Tanah	1

Data yang mengandung *missing value* pada fitur dihapus dari dataset. Pendekatan ini dipilih karena jumlah data yang dihapus relatif kecil dibandingkan total keseluruhan data, sehingga tidak memberikan dampak signifikan terhadap distribusi data. Dengan menghapus data yang tidak lengkap, dataset akhir hanya terdiri dari data yang memiliki informasi yang utuh dan dapat digunakan secara optimal dalam proses pemodelan.

c. *Handling Outliers*

Visualisasi *boxplot* sebelum penanganan *outlier* ditunjukkan pada Gambar 4.1 yang memperlihatkan banyaknya titik data yang berada di luar *whisker boxplot* pada masing-masing fitur.



Gambar 4. 1 Visualisasi *Boxplot Outliers*

Berdasarkan hasil visualisasi menggunakan *boxplot* pada Gambar 4.1, terlihat bahwa sebagian besar fitur numerik pada dataset memiliki sebaran data yang tidak simetris dan mengandung nilai ekstrem. Kondisi ini paling jelas terlihat pada fitur harga rumah, jumlah kamar mandi, luas bangunan, dan luas tanah, terdapat sejumlah data yang berada jauh di luar rentang mayoritas observasi. Jumlah *outlier* sebelum penanganan ditunjukkan pada Tabel 4.3

Tabel 4. 3 Jumlah *Outlier* sebelum Penanganan

Fitur	Jumlah <i>Outlier</i>
Harga Rumah	761
Kamar Tidur	481
Kamar Mandi	1041
Carport	229
Luas Bangunan	614
Luas Tanah	387

Hasil identifikasi *outlier* menggunakan metode *Interquartile Range* (IQR) yang ditunjukkan pada Tabel 4.3 menunjukkan bahwa jumlah *outlier* pada setiap fitur cukup signifikan. Fitur jumlah kamar mandi memiliki jumlah *outlier* tertinggi, yaitu 1.041 data. Kondisi ini mengindikasikan bahwa dataset mengandung banyak nilai ekstrem yang berpotensi memengaruhi proses pembelajaran model.

Penanganan *outlier* dilakukan melalui dua tahap. Pada tahap pertama, metode IQR digunakan untuk menentukan batas bawah dan batas atas nilai yang masih dianggap wajar berdasarkan distribusi data. Tahap ini bertujuan untuk mengidentifikasi observasi yang berada di luar rentang utama distribusi tanpa mengasumsikan bentuk distribusi tertentu. Pada tahap kedua, diterapkan teknik *Winsorization*, yaitu dengan membatasi nilai-nilai ekstrem agar berada pada batas minimum dan maksimum yang telah ditentukan. Pendekatan ini dipilih untuk mengurangi pengaruh nilai ekstrem tanpa harus menghilangkan seluruh data yang teridentifikasi sebagai *outlier*. Dengan demikian, informasi dari data ekstrem masih dipertahankan, namun dampaknya terhadap proses pemodelan dapat diminimalkan.

Setelah proses penanganan *outlier*, jumlah *outlier* pada fitur kamar tidur, kamar mandi, dan carport berhasil dikurangi hingga nol. Sementara itu, fitur harga rumah, luas bangunan, dan luas tanah mengalami penurunan yang signifikan. Secara keseluruhan, proses penanganan *outlier* berhasil mengurangi jumlah nilai ekstrem secara signifikan pada seluruh atribut numerik. Pengurangan jumlah *outlier* ini menghasilkan distribusi data yang lebih stabil dan representatif terhadap kondisi pasar properti secara umum.

d. *Feature Engineering*

Tahap *feature engineering* menghasilkan sejumlah fitur turunan yang dibentuk dari kombinasi fitur utama. Fitur-fitur ini digunakan untuk menangkap informasi yang sebelumnya belum terwakili secara eksplisit oleh fitur dasar, sehingga diharapkan dapat meningkatkan kemampuan model dalam mempelajari pola harga rumah. Hasil *feature engineering* ditunjukkan pada Tabel 4.4

Tabel 4. 4 Hasil *Feature Engineering*

Fitur Baru	Cara <i>Engineering</i>	Keterangan
total_rooms	Kamar tidur + kamar mandi	Total ruangan properti
luas_ratio	Luas bangunan / luas tanah	Proporsi bangunan terhadap lahan
kepadatan_kamar	Total rooms / luas bangunan	Kepadatan ruang dalam bangunan
sisalahan	Luas tanah – luas bangunan	Luas lahan terbuka yang tersisa
bangunan_log	$\ln(1 + \text{luas bangunan})$	Luas bangunan dalam skala log

Fitur Baru	Cara <i>Engineering</i>	Keterangan
harga_per_m2	Harga rumah / luas bangunan	Harga bangunan per meter persegi

Berdasarkan Tabel 4.4, *feature engineering* menghasilkan enam fitur turunan yang merepresentasikan aspek kapasitas ruang, pemanfaatan lahan, kepadatan bangunan, serta nilai ekonomis properti.

e. *Encoding*

Berdasarkan hasil *preprocessing* sebelumnya, fitur lokasi telah melalui proses normalisasi sehingga tidak terdapat perbedaan kategori akibat variasi penulisan. Dengan kondisi tersebut, proses *encoding* dapat dilakukan secara konsisten. Pada tahap ini, dilakukan pemetaan kecamatan ke dalam wilayah geografis yang lebih luas. Setiap nilai pada fitur lokasi dipetakan ke atribut baru berupa wilayah menggunakan skema pemetaan yang telah ditentukan. Setelah berhasil dipetakan ke wilayah yang sesuai, wilayah tersebut dikonversi ke dalam bentuk numerik melalui metode *label encoding*. Hasil *encoding* tersebut menjadi 5 kategori wilayah yang ditunjukkan pada Tabel 4.5, sehingga kompleksitas fitur lokasi dapat dikurangi tanpa menghilangkan informasi spasial yang relevan. Pendekatan ini digunakan untuk mencegah tingginya dimensi fitur yang berpotensi memengaruhi performa model.

Tabel 4. 5 Hasil *Encoding*

Kategori Wilayah	Wilayah yang terdaftar	<i>Encoding</i>
Utara	Cidadap, Coblong, Sukajadi, Sukasari, Cibeunying Kaler	1
Tengah	Andir, Astanaanyar, Cicendo, Sumur Bandung, Bandung Wetan, Regol, Lengkong	2

Kategori Wilayah	Wilayah yang terdaftar	Encoding
Barat	Bandung Kulon, Bojongloa Kaler, Bojongloa Kidul, Babakan Ciparay	3
Selatan	Bandung Kidul, Batununggal, Buahbatu, Kiaracondong, Cibeunying Kidul	4
Timur	Antapani, Arcamanik, Cibiru, Gedebage, Mandalajati, Panyileukan, Rancasari, Ujung Berung, Cinambo	5


Dengan selesainya tahap *encoding*, seluruh fitur dalam dataset telah berada dalam format numerik dan siap digunakan pada tahap berikutnya.

4.3 *Exploratory Data Analysis*

Proses *Exploratory Data Analysis* digunakan untuk menganalisis karakteristik data numerik setelah melalui tahap preprocessing dan pembentukan fitur turunan. Dalam proses *Exploratory Data Analysis* ini terdapat 3 bagian di dalamnya, yaitu:


a. Analisis Distribusi Data

Analisis distribusi data dilakukan menggunakan *histogram* terhadap seluruh fitur numerik. Berikut hasil visualisasi *histogram*:




Gambar 4. 2 *Histogram* Kamar Tidur, Kamar Mandi, Carport, Luas Bangunan, Luas Tanah, dan Harga Rumah

Pada Gambar 4.2 *histogram* kamar tidur, kamar mandi, dan carport menunjukkan distribusi diskret dengan puncak pada nilai tertentu. Mayoritas rumah memiliki dua hingga tiga kamar tidur, satu hingga dua kamar mandi, dan satu carport. Nilai di luar rentang tersebut jumlahnya jauh lebih sedikit, sehingga dapat disimpulkan bahwa karakteristik rumah dalam dataset relatif seragam. *Histogram* luas bangunan dan luas tanah menunjukkan distribusi miring ke kanan, dengan sebagian besar data berada pada nilai kecil hingga menengah. Rumah dengan luas bangunan dan luas tanah yang sangat besar hanya muncul pada sedikit data. Pola yang terlihat pada *histogram* harga rumah, harga rendah hingga menengah lebih dominan dibandingkan harga yang sangat tinggi.



Gambar 4. 3 *Histogram* total rooms, luas ratio, kepadatan kamar, sisa lahan, bangunan log, dan harga per meter persegi

Pada Gambar 4.3 *histogram* total rooms menunjukkan jumlah total ruang paling banyak berada pada rentang empat sampai tujuh ruangan. Jumlah ruangan yang sangat sedikit atau sangat banyak jarang ditemukan. *Histogram* rasio luas bangunan terhadap luas tanah menunjukkan bahwa sebagian besar rumah memiliki luas bangunan yang mendekati luas tanah. *Histogram* kepadatan kamar memperlihatkan bahwa sebagian besar rumah memiliki jumlah kamar yang sebanding dengan luas bangunannya. *Histogram* sisa lahan menunjukkan bahwa banyak rumah memiliki sisa lahan yang kecil. *Histogram* bangunan log terlihat lebih simetris dibandingkan histogram luas bangunan. *Histogram* harga per meter persegi memperlihatkan bahwa sebagian besar rumah memiliki harga per meter persegi yang rendah hingga menengah, sementara nilai yang sangat tinggi jarang muncul pada data.




Gambar 4. 4 *Histogram* Wilayah Encoded

Pada Gambar 4.4 *histogram* wilayah hasil proses *encoding* menunjukkan bahwa jumlah data tidak sama di setiap wilayah. Beberapa wilayah memiliki jumlah data yang lebih banyak dibandingkan wilayah lainnya. Hal ini menunjukkan bahwa penawaran rumah dalam dataset lebih terkonsentrasi di wilayah tertentu.

b. Analisis Korelasi Fitur

Analisis korelasi dilakukan untuk mengidentifikasi hubungan linear antar fitur numerik serta hubungannya dengan variabel target harga rumah. Visualisasi korelasi disajikan dalam bentuk heatmap matriks korelasi untuk memudahkan interpretasi tingkat hubungan antar variabel. Berikut hasil visualisasi korelasi fitur:



Gambar 4. 5 *Heatmap* Korelasi Fitur

Berdasarkan hasil visualisasi heatmap pada Gambar 4.5, terlihat bahwa terdapat variasi tingkat korelasi antar fitur, baik yang bersifat positif maupun negatif, dengan intensitas yang berbeda-beda. Fitur-fitur yang berkaitan langsung dengan ukuran fisik properti menunjukkan korelasi positif yang relatif lebih kuat terhadap harga rumah. Luas bangunan, luas tanah, total room, serta bangunan log memiliki nilai korelasi yang lebih tinggi dibandingkan fitur lainnya. Hal ini menunjukkan bahwa semakin besar ukuran dan kapasitas rumah, maka harga rumah cenderung


meningkat. Pola ini sejalan dengan karakteristik pasar properti, di mana ukuran fisik rumah menjadi salah satu indikator utama dalam penentuan harga.

Korelasi yang cukup tinggi antara luas bangunan dan bangunan log mengindikasikan bahwa transformasi logaritmik yang diterapkan tidak menghilangkan informasi utama dari fitur asli, melainkan membantu menstabilkan variasi data dan mengurangi pengaruh nilai ekstrem. Dengan demikian, fitur bangunan log tetap merepresentasikan hubungan yang kuat dengan harga rumah, sekaligus memiliki karakteristik distribusi yang lebih mendekati normal dibandingkan fitur luas bangunan asli.

Sementara itu, beberapa fitur lain seperti luas ratio, kepadatan kamar, dan sisa lahan menunjukkan korelasi yang relatif rendah terhadap harga rumah. Hal ini mengindikasikan bahwa pengaruh fitur-fitur tersebut tidak berdiri sendiri, melainkan bergantung pada kombinasi dengan fitur lain. Variabel wilayah juga menunjukkan korelasi yang relatif rendah terhadap harga rumah. Kondisi ini mengindikasikan bahwa pengaruh lokasi terhadap harga rumah tidak sepenuhnya bersifat linear dan tidak dapat direpresentasikan secara langsung melalui hubungan korelasi sederhana. Meskipun demikian, perbedaan nilai korelasi antar wilayah tetap menunjukkan adanya variasi karakteristik harga rumah yang dipengaruhi oleh lokasi.


c. Analisis Pola Hubungan Fitur

Analisis *scatter plot* dilakukan untuk mengamati pola hubungan antara masing-masing fitur prediktor dengan harga rumah secara visual, serta untuk mengidentifikasi pola *non-linear* dan tingkat penyebaran data. Hasil visualisasi *scatter plot* ditunjukkan pada Gambar 4.6 dan 4.7 berikut:



Gambar 4. 6 *Scatter plot* Kamar Tidur, Kamar Mandi, Carport, Luas Bangunan, Luas Tanah, dan Total Rooms

Pada Gambar 4.6 *scatter plot* kamar tidur, kamar mandi, carport, dan total rooms terhadap harga rumah menunjukkan bahwa pada jumlah fasilitas yang sama, harga rumah dapat bervariasi cukup besar. Hal ini terlihat dari sebaran titik yang melebar secara vertikal. Kondisi ini menunjukkan bahwa jumlah kamar dan fasilitas bukan satu-satunya faktor penentu harga rumah. *Scatter plot* luas bangunan dan luas tanah terhadap harga rumah menunjukkan pola kenaikan harga seiring bertambahnya luas. Namun, pada nilai luas yang besar, sebaran harga menjadi semakin lebar. Hal ini menandakan bahwa rumah dengan ukuran besar dapat memiliki harga yang sangat bervariasi, tergantung dengan faktor lain seperti lokasi.




Gambar 4. 7 *Scatter plot* Bangunan Log dan Harga per Meter Persegi

Pada Gambar 4.7 *scatter plot* bangunan log terhadap harga rumah menunjukkan pola hubungan yang lebih jelas dibandingkan luas bangunan asli. Titik data menjadi lebih terkonsentrasi dan tren kenaikan harga terlihat lebih rapi. Hal ini menunjukkan bahwa transformasi logaritmik membantu memperjelas hubungan antara luas bangunan dan harga rumah. *Scatter plot* harga per meter persegi terhadap harga rumah menunjukkan sebaran yang cukup lebar, terutama pada nilai harga per meter persegi yang rendah. Hal ini menunjukkan bahwa harga per meter persegi belum cukup untuk menjelaskan variasi harga rumah secara keseluruhan.

d. Analisis Distribusi Jumlah Rumah

Analisis distribusi jumlah rumah per wilayah dilakukan menggunakan *count plot* untuk melihat sebaran data berdasarkan wilayah di Kota Bandung. Hasil visualisasi *count plot* ditunjukkan pada Gambar 4.8



Gambar 4. 8 *Count plot* Jumlah Rumah per Wilayah

Berdasarkan Gambar 4.8, terlihat bahwa jumlah data rumah tidak terdistribusi secara merata pada seluruh wilayah. Wilayah Timur memiliki jumlah rumah paling banyak, diikuti oleh wilayah Tengah dan Selatan, sedangkan wilayah Utara memiliki jumlah data paling sedikit.

Ketimpangan distribusi ini mencerminkan kondisi pasar properti, di mana aktivitas penawaran rumah lebih terkonsentrasi pada wilayah tertentu.


Banyaknya data pada wilayah Timur dan Tengah menunjukkan bahwa kedua wilayah tersebut memiliki aktivitas pembangunan dan transaksi properti yang relatif lebih tinggi dibandingkan wilayah lainnya. Sebaliknya, jumlah data yang lebih sedikit pada wilayah Utara mengindikasikan keterbatasan penawaran atau karakteristik kawasan yang berbeda. Distribusi data yang tidak seimbang antar wilayah berpotensi memengaruhi proses pembelajaran model, karena model cenderung lebih banyak mempelajari pola dari wilayah dengan jumlah data yang lebih dominan. Oleh karena itu, fitur wilayah tetap dipertahankan dalam proses pemodelan untuk menangkap perbedaan karakteristik harga antar wilayah, meskipun pengaruhnya tidak sepenuhnya bersifat *linear*.

4.4 Feature Selection

Setelah tahap *Exploratory Data Analysis* selesai, dilakukan proses seleksi fitur untuk mengidentifikasi fitur yang paling relevan terhadap variabel target harga rumah. Seleksi fitur dilakukan menggunakan dua pendekatan, yaitu analisis korelasi *Pearson* dan metode *SelectKBest* dengan fungsi *f_regression*. Kedua metode ini digunakan untuk memastikan konsistensi hasil seleksi berdasarkan hubungan linear antara fitur dan harga rumah.

a. Analisis Korelasi *Pearson*

Hasil korelasi *Pearson* ditunjukkan dalam Gambar 4.9 dan Tabel 4.6 berikut:



Gambar 4. 9 Korelasi Fitur Terhadap Harga

Berdasarkan grafik korelasi, fitur luas bangunan memiliki korelasi positif paling kuat terhadap harga rumah. Hal ini terlihat dari nilai korelasi yang paling tinggi dibandingkan fitur lainnya, yang menunjukkan bahwa semakin besar luas bangunan, harga rumah semakin cenderung tinggi. Fitur bangunan log dan luas tanah menunjukkan korelasi positif yang cukup kuat terhadap harga. Hal ini menunjukkan bahwa ukuran bangunan dalam skala logaritmik maupun luas tanah memiliki hubungan yang jelas dengan peningkatan harga rumah. Fitur total rooms, kamar tidur, kamar mandi, dan carport memiliki korelasi positif sedang. Hal ini menunjukkan bahwa jumlah ruang dan fasilitas berkaitan dengan kenaikan harga, tetapi pengaruhnya tidak sekuat luas bangunan dan luas tanah. Sebaliknya, fitur kepadatan kamar menunjukkan korelasi negatif terhadap harga rumah. Hal ini berarti rumah dengan jumlah kamar yang terlalu padat terhadap luas bangunan cenderung memiliki harga yang lebih rendah. Fitur sisa lahan dan luas ratio menunjukkan korelasi yang sangat lemah, sehingga pengaruh dengan harga rumah relatif kecil.

Tabel 4. 6 Hasil Korelasi *Pearson*


Fitur	Skor Fitur
Harga rumah	1.000000
Luas bangunan	0.824548
Bangunan log	0.744568
Luas tanah	0.705853
Fitur	Skor Fitur
Total rooms	0.387750
Kamar mandi	0.355517
Kamar tidur	0.346917

Fitur	Skor Fitur
Carport	0.235342
Harga per meter persegi	0.116741
Luas ratio	0.069377
Sisa lahan	-0.01679
Kepadatan kamar	-0.480477

Berdasarkan hasil analisis korelasi *Pearson* pada Tabel 4.6, menunjukkan bahwa harga rumah lebih dipengaruhi oleh ukuran dan proporsi bangunan dibandingkan oleh jumlah fasilitas yang dimiliki. Penambahan kamar tidur, kamar mandi, atau ruang lain tidak selalu diikuti oleh kenaikan harga yang signifikan apabila tidak disertai peningkatan luas bangunan. Hubungan negatif pada kepadatan kamar mengindikasikan bahwa rumah dengan pembagian ruang yang terlalu padat terhadap luas bangunan cenderung memiliki nilai jual yang lebih rendah. Kondisi tersebut mencerminkan tata ruang yang kurang proporsional, sehingga meskipun jumlah kamarnya lebih banyak, nilai ekonominya justru menurun. Berdasarkan hasil ini, seleksi awal mempertahankan fitur dengan korelasi absolut ≥ 0.30 .

b. Seleksi Fitur Menggunakan SelectKBest

Tahap selanjutnya dilakukan seleksi fitur menggunakan metode *SelectKBest* dengan fungsi *f_regression*. Hasil ini ditunjukkan pada Gambar 4.10 dan Tabel 4.7 berikut:



Gambar 4. 10 Skor Fitur Berdasarkan *SelectKBest*

Pada Gambar 4.10 menunjukkan bahwa luas bangunan memiliki skor tertinggi, yang menandakan fitur ini paling relevan dalam menjelaskan variasi harga rumah. Fitur bangunan log dan luas tanah juga memiliki skor yang tinggi, sehingga keduanya merupakan fitur penting dalam pemodelan harga rumah. Fitur kepadatan kamar, total rooms, kamar mandi, dan kamar tidur memiliki skor menengah hingga rendah. Hal ini menunjukkan bahwa fitur-fitur tersebut tetap berkontribusi, namun pengaruhnya tidak sebesar ukuran fisik bangunan dan tanah. Fitur carport, harga per meter persegi, luas ratio, dan sisa lahan memiliki skor yang sangat rendah. Ini menunjukkan bahwa pengaruh fitur-fitur tersebut terhadap variasi harga rumah relatif lemah.

Tabel 4. 7 Hasil *SelectKBest*

Fitur	Skor Fitur
Luas bangunan	13486.251229
Bangunan log	7899.868074
Luas tanah	6305.148380
Kepadatan kamar	1905.957194
Total rooms	1123.664056

Fitur	Skor Fitur
Kamar mandi	918.709572
Kamar tidur	868.793771
Carport	372.322038
Harga per meter persegi	87.736715
Luas ratio	30.711520
Sisa lahan	0.017911

Pada tahap ini, jumlah fitur yang dipilih ditetapkan sebanyak tujuh fitur terbaik ($k=7$). Berdasarkan hasil *SelectKBest* pada Tabel 4.7 tersebut, diperoleh tujuh fitur numerik yang digunakan dalam tahapan pemodelan, yaitu kamar tidur, kamar mandi, total rooms, kepadatan kamar, luas tanah, bangunan log, dan luas bangunan. Hasil seleksi ini menunjukkan bahwa ukuran fisik bangunan merupakan faktor utama dalam menjelaskan variasi harga rumah, yang tercermin dari dominasi fitur luas bangunan, bangunan log, dan luas tanah. Fitur total rooms, kamar mandi, dan kamar tidur berperan sebagai pelengkap yang merepresentasikan kapasitas dan fungsi ruang, sementara kepadatan kamar tetap terpilih karena memiliki hubungan linear yang konsisten terhadap harga rumah meskipun arahnya negatif. Ketujuh fitur numerik yang terpilih tersebut digunakan sebagai input utama pada tahap pemodelan menggunakan *Support Vector Regression*, bersama dengan fitur lokasi yang telah melalui proses *encoding*. Pendekatan seleksi fitur ini memastikan bahwa model dibangun menggunakan fitur yang informatif, efisien, dan minim noise.

4.5 Data Split

Setelah proses seleksi fitur selesai, dataset dibagi menjadi data latih dan data uji menggunakan fungsi *train_test_split* dari pustaka *scikit-learn*. Pada tahap ini fitur prediktor direpresentasikan oleh variabel x , sedangkan harga rumah sebagai

variabel target direpresentasikan oleh y . Pembagian data dilakukan dengan proporsi 80% data latih dan 20% data uji, yang ditentukan melalui parameter `test_size=0.2`. proporsi ini dipilih untuk memastikan bahwa model memperoleh jumlah data yang cukup pada tahap pelatihan, sekaligus menyediakan data uji yang memadai untuk mengevaluasi performa model secara objektif. Parameter `random_state=42` digunakan untuk menjaga konsistensi hasil pembagian data. Dengan menetapkan nilai `random_state`, proses pembagian data dapat direplikasi sehingga hasil eksperimen bersifat stabil dan dapat diuji ulang. Hasil *Data split* ditunjukkan pada Tabel 4.8

Tabel 4. 8 Hasil *Data split*

Jenis Data	Data Latih	Data Uji
Jumlah Data	5081	1271

Data latih digunakan dalam proses pemodelan, termasuk standarisasi fitur, pelatihan model, serta optimasi parameter. Sementara itu, data uji hanya digunakan pada tahap evaluasi akhir untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya. Dengan melakukan *Data splitting* sebelum tahap pemodelan, proses evaluasi model dapat dilakukan tanpa adanya kebocoran data (*data leakage*). Hal ini memastikan bahwa nilai performa model yang diperoleh benar-benar mencerminkan kemampuan prediksi model terhadap data baru.

4.6 Modelling

Tahap pemodelan dalam penelitian ini bertujuan untuk membangun dan mengevaluasi model prediksi harga rumah menggunakan algoritma *Support Vector Regression* secara bertahap dan sistematis. Pemodelan tidak dilakukan secara langsung dengan konfigurasi terbaik, melainkan diawali dengan penggunaan konfigurasi standar (*default*) sebagai acuan awal, kemudian dilanjutkan dengan proses optimasi *hyperparameter* untuk memperoleh peningkatan performa.

Pada tahap awal, model *Baseline SVR* dibangun menggunakan konfigurasi parameter default yang disediakan oleh pustaka *scikit-learn*. Model *Baseline*

digunakan untuk merepresentasikan kemampuan awal algoritma *SVR* dalam memprediksi harga rumah tanpa adanya penyesuaian parameter. Penggunaan model *Baseline* penting untuk memberikan pembandingan yang objektif, sehingga proses *hyperparameter* tuning pada tahap selanjutnya dapat dievaluasi secara jelas.

Seluruh proses pemodelan dilakukan menggunakan *pipeline* yang menggabungkan proses standarisasi fitur dan algoritma *Support Vector Regression* dalam satu alur pemrosesan. Standarisasi fitur dilakukan menggunakan *StandardScaler* agar seluruh fitur memiliki skala yang sebanding, karena algoritma *SVR* sensitif terhadap perbedaan skala antar fitur. Penggunaan *pipeline* juga bertujuan untuk menjaga konsistensi proses pengolahan data serta mencegah terjadinya kebocoran data (*data leakage*), di mana proses standarisasi hanya dilakukan berdasarkan data latih.

Pemodelan dilakukan menggunakan data yang telah dibagi menjadi data latih dan data uji. Data latih digunakan untuk melatih model, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi pada data yang belum pernah dilihat sebelumnya. Pada tahap pemodelan, analisis kinerja model difokuskan terlebih dahulu pada data latih untuk melihat sejauh mana model mampu mempelajari pola hubungan antara fitur dan harga rumah. Hasil evaluasi pada data uji kemudian digunakan sebagai pendukung untuk menilai kestabilan dan kemampuan generalisasi model. Evaluasi dilakukan menggunakan tiga metrik utama, yaitu *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), dan *R Squared* (R^2). Ketiga metrik ini dipilih karena mampu memberikan Gambaran menyeluruh mengenai tingkat kesalahan prediksi dan kemampuan model dalam menjelaskan variasi data.

Setelah kinerja model *Baseline* dianalisis, proses pemodelan dilanjutkan dengan optimasi *hyperparameter*. Optimasi dilakukan menggunakan tiga metode, yaitu *Grid Search*, *Random Search*, dan *Bayesian Optimization*. Ketiga metode tersebut digunakan untuk membandingkan efektivitas strategi pencarian parameter yang berbeda, baik secara menyeluruh, acak, maupun adaptif. Setiap metode dievaluasi menggunakan skema *cross-validation* dengan jumlah lipatan 3, 5, dan

10 untuk melihat pengaruh jumlah lipatan terhadap stabilitas performa model dan menentukan konfigurasi model yang paling optimal.

4.7 Evaluasi *Baseline*


Evaluasi model *Baseline* dilakukan untuk melihat kemampuan awal model *SVR* dalam memprediksi harga rumah di Kota Bandung sebelum dilakukan optimasi *hyperparameter*. Hasil evaluasi model *Baseline* ditunjukkan pada Tabel 4.9 berikut:

Tabel 4. 9 Hasil *Baseline* Model

Data	MSE	RMSE	R ²	Waktu Komputasi
Train	20.411.758,37	4.517,94	-0.0064	0.01 detik
Tes	14.981.495,53	3.870,59	0.0252	-


Berdasarkan hasil pada Tabel 4.9, dapat dilihat bahwa model *Baseline* belum mampu mempelajari pola hubungan antara karakteristik rumah dan harga secara memadai. Nilai R² yang sangat rendah pada data uji serta data latih bernilai negatif menunjukkan bahwa model hampir tidak mampu menjelaskan variasi harga rumah yang terdapat pada dataset. Hal ini mengindikasikan bahwa model *SVR* dengan parameter *default* belum sesuai dengan kompleksitas data harga di Kota Bandung yang memiliki rentang harga sangat lebar dan dipengaruhi oleh banyak faktor.

Besarnya nilai RMSE menunjukkan bahwa selisih antara harga prediksi dan harga aktual masih cukup jauh. Kondisi ini dapat dikaitkan dengan karakteristik data, di mana harga rumah di Bandung memiliki variasi ekstrem, mulai dari ratusan juta hingga puluhan miliar rupiah. Perbedaan harga rumah yang cukup besar menyebabkan model *SVR* dengan parameter default belum mampu menangkap pola data dengan baik. Hasil ini menunjukkan bahwa model masih mengalami *underfitting*, sehingga diperlukan optimasi *hyperparameter* untuk meningkatkan kinerja prediksi.



Gambar 4. 11 *Plot Aktual vs Prediksi Baseline*

Pada Gambar 4.11 *plot* Aktual vs prediksi model *Baseline* menunjukkan bahwa sebagian besar titik prediksi tidak berada di sekitar garis ideal. Nilai prediksi cenderung terkonsentrasi pada rentang harga rendah hingga menengah, sementara nilai aktual tersebar hingga harga yang lebih tinggi. Pada harga rumah yang tinggi, terlihat bahwa banyak titik prediksi berada di bawah garis ideal, yang menunjukkan bahwa model belum mampu memprediksi harga tinggi dengan baik.



Gambar 4. 12 *Residual Plot Baseline*

Pada Gambar 4.12 *residual plot Baseline* memperlihatkan bahwa *residual* tidak menyebar secara acak di sekitar garis nol. Pola *residual* semakin melebar seiring meningkatnya nilai prediksi, yang mengindikasikan bahwa kesalahan prediksi menjadi lebih besar pada harga rumah yang lebih tinggi. Kondisi ini menunjukkan bahwa model *Baseline* belum mampu menghasilkan prediksi yang stabil.

Rendahnya performa model *Baseline* ini disebabkan oleh penggunaan parameter default *SVR* yang belum sesuai dengan karakteristik data harga rumah di Kota Bandung. Meskipun waktu komputasi relatif singkat, hasil evaluasi dan visualisasi menunjukkan bahwa kemampuan prediksi model masih terbatas. Oleh karena itu, model *Baseline* digunakan sebagai acuan awal untuk dilakukan proses optimasi *hyperparameter* pada tahap selanjutnya.

4.8 *Hyperparameter Tuning*

Optimasi *hyperparameter* dilakukan setelah model *baseline SVR* menunjukkan performa yang belum optimal. Tujuan dari tahap ini adalah meningkatkan akurasi prediksi serta kemampuan generalisasi model terhadap data yang belum pernah dilihat. Pada penelitian ini digunakan tiga metode optimasi, yaitu *Grid Search*, *Random Search*, dan *Bayesian Optimization*.

Seluruh proses *hyperparameter tuning* dilakukan menggunakan *pipeline* yang sama seperti pada model *Baseline*, yaitu *StandardScaler* dan algoritma *SVR*. Orientasi utama evaluasi difokuskan pada nilai *R Squared* (R^2) sebagai metrik akurasi prediksi, serta waktu komputasi sebagai indikator efisiensi proses optimasi. Evaluasi setiap metode dilakukan menggunakan *cross validation* dengan 3, 5, dan 10 lipatan dengan *search space* yang sama untuk menjaga keadilan perbandingan. *Search space* ditunjukkan pada Tabel 4.10 berikut:

Tabel 4. 10 *Search Space*

Parameter	CV 3	CV 5	CV 10
Kernel	RBF, Poly, Sigmoid	RBF, Poly, Sigmoid	RBF, Poly, Sigmoid
C	3, 6	5, 10, 20	8, 10, 12
Epsilon	0.02, 0.04	0.03, 0.05	0.025, 0.03, 0.035
Gamma	Scale	Scale	Scale
Degree	2	2	2
Coef0	0	0	0

Search space dibuat sama untuk setiap metode dalam skema CV yang sama, namun berbeda antar skema CV. Perbedaan ini bertujuan untuk menyesuaikan luas pencarian parameter dengan tingkat kompleksitas dan waktu komputasi masing-masing skema CV.

a. *Hyperparameter Tuning* dengan *Grid Search*

Grid Search merupakan metode optimasi *hyperparameter* yang melakukan pencarian secara menyeluruh terhadap seluruh kombinasi parameter yang telah ditentukan. Hasil dari *Grid Search* ditunjukkan pada Tabel 4.11


Tabel 4. 11 Hasil *Grid Search*

Metrik Evaluasi	CV 3	CV 5	CV 10	AVG
R ² CV	0.7658	0.7638	0.7609	0.7635
MSE CV	4.750.360,76	4.790.962,86	4.850.233,44	4.797.185,69
RMSE CV	2.179,53	2.188,83	2.202,32	2.190,22
Waktu Training & Tuning	0:49	3:13	11:19	5:07
Ukuran Model	313,18 KB	305,09 KB	316,34 KB	-
R ² Tes	0.6943	0.7008	0.7088	0.7013
MSE Tes	4.697.779,12	4.597.804,94	4.475.487,31	4.590.357,12
RMSE Tes	2.167,44	2.144,25	2.155,53	2.142,40
Best params	C: 3, epsilon: 0.04, gamma: scale, kernel: rbf	C: 5, epsilon: 0.05, gamma: scale, kernel: rbf	C: 8, epsilon: 0.035, gamma: scale, kernel: rbf	-

Berdasarkan Tabel 4.11 hasil evaluasi *Grid Search* pada berbagai skema *cross-validation*, terlihat bahwa jumlah *fold* memengaruhi cara model mempelajari data. Pada CV 3, model lebih fokus pada pola data latih sehingga kinerja pelatihan terlihat lebih baik. Namun, performa model kurang stabil ketika dihadapkan pada data yang berbeda.


Ketika jumlah *fold* ditingkatkan menjadi CV 5 dan CV 10, data latih dibagi menjadi bagian yang lebih kecil dan beragam. Hal ini menjadikan model untuk belajar dari variasi data yang lebih luas, sehingga performa pada data uji menjadi lebih stabil, yang ditunjukkan dari peningkatan R^2 pada data uji serta penurunan *error* prediksi. Hal ini relevan dengan karakteristik data harga rumah yang memiliki variasi cukup tinggi, terutama pada rentang harga menengah hingga tinggi.

Secara keseluruhan, *Grid Search* dengan jumlah *fold* yang lebih besar menghasilkan model yang lebih konsisten dalam memprediksi harga rumah. Meskipun waktu komputasi meningkat, CV 10 memberikan keseimbangan yang lebih baik antara kestabilan model dan kemampuan generalisasi pada data harga rumah di Kota Bandung. Berikut adalah hasil visualisasi *plot* aktual vs prediksi dan *plot residual Grid Search*:




Gambar 4. 13 *Plot* Aktual vs Prediksi *Grid Search* CV 3

Pada Gambar 4.13 *plot* aktual vs prediksi menunjukkan perbaikan dibandingkan dengan model *Baseline*. Titik-titik prediksi mulai mendekati garis ideal, terutama pada rentang harga rendah hingga menengah. Meskipun demikian, pada nilai aktual yang tinggi masih terlihat penyebaran titik belum sepenuhnya akurat.




Gambar 4. 14 *Residual Plot Grid Search CV 3*

Hasil Gambar 4.14 *residual plot* pada CV 3 ini memperlihatkan distribusi *residual* yang lebih terpusat di sekitar garis nol dibandingkan model *Baseline*. Namun, masih tampak adanya *residual* dengan nilai yang cukup besar, baik positif maupun negatif. Pola *residual* belum sepenuhnya acak dan masih menunjukkan peningkatan dispersi pada nilai prediksi yang lebih tinggi. Hal ini mengindikasikan bahwa meskipun terjadi peningkatan performa, model masih mengalami kesulitan dalam memprediksi rumah dengan harga ekstrem.




Gambar 4. 15 *Plot Aktual vs Prediksi Grid Search CV 5*

Pada Gambar 4.15 *plot* aktual vs prediksi pada skema *Grid Search* CV 5 menunjukkan pola prediksi yang lebih konsisten dibandingkan dengan CV 3. Titik-titik prediksi semakin rapat mengikuti garis ideal, khususnya pada rentang harga yang paling banyak muncul dalam dataset. Penyebaran titik masih terlihat pada harga rumah yang tinggi, namun pola keseluruhan menunjukkan kedekatan yang lebih baik antara nilai aktual dan nilai prediksi.




Gambar 4. 16 *Residual Plot Grid Search CV 5*

Hasil dari Gambar 4.16 *residual plot* pada CV 5 memperlihatkan penyebaran *residual* yang lebih terkendali. Sebagian besar *residual* berada di sekitar garis nol, dengan dispersi yang relatif lebih kecil dibandingkan dengan CV 3. Meskipun masih terdapat beberapa *residual* ekstrem, terutama pada nilai prediksi yang besar, pola *residual* secara umum lebih simetris dan tidak menunjukkan tren yang terlalu kuat. Hal ini menunjukkan bahwa peningkatan jumlah lipatan *cross-validation* membantu menghasilkan prediksi yang lebih stabil.



Gambar 4. 17 *Plot* Aktual vs Prediksi *Grid Search* CV 10

Pada Gambar 4.17 *plot* aktual vs prediksi skema *Grid Search* CV 10, menunjukkan hasil yang paling mendekati garis ideal dibandingkan dengan seluruh skema sebelumnya. Titik-titik prediksi tersebar lebih merata dan mengikuti arah garis diagonal, yang mengindikasikan bahwa model mampu merepresentasikan hubungan antara nilai aktual dan prediksi dengan lebih baik. Meskipun pada harga rumah yang sangat tinggi masih terdapat penyimpangan, pola keseluruhan menunjukkan peningkatan konsistensi prediksi.



Gambar 4. 18 *Residual Plot Grid Search CV 10*

Residual plot pada CV 10 pada Gambar 4.18 menunjukkan distribusi *residual* yang paling mendekati acak di sekitar garis nol. Pola kipas yang sebelumnya terlihat pada model *Baseline* dan CV yang lebih kecil menjadi jauh berkurang. Sebagian besar *residual* memiliki nilai yang relatif kecil, dan tidak tampak pola sistematis yang dominan. Kondisi ini menunjukkan bahwa model dengan CV 10 menghasilkan kesalahan prediksi yang lebih stabil dan memiliki kemampuan generalisasi yang lebih baik dibandingkan skema lainnya.

b. *Hyperparameter Tuning dengan Random Search*

Random Search merupakan metode optimasi *hyperparameter* yang melakukan pencarian parameter secara acak dalam ruang parameter yang telah ditentukan. Hasil dari *Random Search* ditunjukkan pada Tabel 4.12


Tabel 4. 12 Hasil *Random Search*

Metrik Evaluasi	CV 3	CV 5	CV 10	AVG
R ² CV	0.7658	0.7638	0.7597	0.7631
MSE CV	4.479.665,47	4.790.962,86	4.873.790,47	4.804.806,27
RMSE CV	2.179,37	2.188,83	2.207,67	2.191,95
Waktu Training & Tuning	0:18	1:46	4:48	2:17
Ukuran Model	332,80 KB	305,09 KB	327,88 KB	-
R ² Tes	0.6973	0.7008	0.7110	0.7030
MSE Tes	4.652.139,85	4.597.804,94	4.441.286,55	4.563.743,78
RMSE Tes	2.156,88	2.144,25	2.107,44	2.136,19
Best params	kernel: rbf, gamma: scale, epsilon: 0.02, C: 3	kernel: rbf, gamma: scale, epsilon: 0.05, C: 5	kernel: rbf, gamma: scale, epsilon: 0.025, C: 8	-

Berdasarkan Tabel 4.12 hasil evaluasi *Random Search* pada berbagai skema cross-validation, terlihat bahwa perubahan jumlah *fold* memengaruhi stabilitas performa model, namun dengan karakteristik yang berbeda dibandingkan *Grid Search*. Pada CV 3, *Random Search* sudah mampu menghasilkan performa yang baik pada data latih dengan waktu komputasi yang sangat singkat. Hal ini menunjukkan bahwa *Random Search* efektif dalam menemukan kombinasi *hyperparameter* yang relevan tanpa harus mengevaluasi seluruh ruang parameter. Temuan ini sejalan dengan penelitian F. W. Hartono et al. [8] yang menyatakan bahwa *Random Search* mampu menemukan kombinasi *hyperparameter* yang baik secara efisien.


Pada CV 5 dan CV 10, performa pada data uji menunjukkan peningkatan yang lebih konsisten, ditandai dengan nilai R^2 uji yang semakin tinggi dan RMSE yang semakin kecil. Pola ini menunjukkan bahwa *Random Search* tetap mampu mempertahankan efisiensi pencarian parameter sekaligus meningkatkan kemampuan generalisasi model ketika dilatih dengan variasi data yang lebih luas. Kondisi ini relevan dengan karakteristik data harga rumah di Kota Bandung yang memiliki sebaran nilai cukup lebar, terutama pada harga menengah hingga tinggi.

Random Search dengan CV 10 memberikan keseimbangan terbaik antara akurasi prediksi dan kestabilan model, dengan peningkatan performa pada data uji tanpa kenaikan waktu komputasi yang terlalu drastis. Secara keseluruhan, hasil ini menunjukkan bahwa *Random Search* merupakan metode *hyperparameter tuning* yang efisien dan stabil untuk model *SVR*, serta lebih adaptif terhadap variasi data dibandingkan pendekatan pencarian menyeluruh. Berikut adalah hasil visualisasi *plot* aktual vs prediksi dan *plot residual Random Search*:




Gambar 4. 19 *Plot Aktual vs Prediksi Random Search CV 3*

Pada Gambar 4.19 skema *Random Search CV 3*, *plot* aktual vs prediksi menunjukkan bahwa sebaran titik prediksi sudah mengikuti arah garis ideal dengan lebih baik dibandingkan dengan model *Baseline*. Titik-titik prediksi tampak lebih menyebar sepanjang garis diagonal, terutama pada rentang harga rendah hingga menengah, yang mengindikasikan bahwa model mulai mampu merepresentasikan hubungan antara nilai aktual dan nilai prediksi. Meskipun demikian, pada harga rumah yang tinggi masih terlihat penyimpangan, di mana beberapa titik prediksi berada cukup jauh dari garis ideal, sehingga prediksi pada harga tinggi belum sepenuhnya tercapai.




Gambar 4. 20 *Residual Plot Random Search CV 3*

Residual plot pada *Random Search CV 3* pada Gambar 4.20 menunjukkan bahwa sebagian besar *residual* berada di sekitar garis nol, namun sebaran *residual* masih melebar pada nilai prediksi yang lebih tinggi. Pola ini menunjukkan bahwa kesalahan prediksi cenderung meningkat seiring bertambahnya nilai prediksi. Meskipun distribusi *residual* lebih baik dibandingkan model *Baseline*, masih terlihat adanya *residual* ekstrem yang menandakan bahwa model belum sepenuhnya menghasilkan kesalahan yang bersifat acak.




Gambar 4. 21 *Plot Aktual vs Prediksi Random Search CV 5*

Pada Gambar 4.21 *Random Search CV 5*, *plot* aktual vs prediksi menunjukkan bahwa sebagian besar titik prediksi telah mengikuti arah garis ideal, terutama pada rentang harga rendah hingga menengah. Namun, seiring meningkatnya nilai harga aktual, sebaran titik prediksi menjadi semakin menyebar dan menjauh dari garis diagonal. Hal ini mengindikasikan bahwa model masih mengalami kesulitan dalam menangkap pola harga rumah dengan nilai yang sangat tinggi, sehingga akurasi prediksi pada segmen tersebut relatif menurun.




Gambar 4. 22 *Residual Plot Random Search CV 5*

Residual plot pada CV 5 pada Gambar 4.22 memperlihatkan pola *residual* yang belum sepenuhnya acak. Terlihat adanya pola kipas di mana variansi *residual* meningkat pada nilai prediksi yang lebih besar. Selain itu, masih terdapat beberapa *residual* ekstrem, baik positif maupun negatif, yang menandakan adanya prediksi yang cukup meleset. Kondisi ini menunjukkan bahwa model sudah mampu memberikan prediksi yang cukup baik secara umum.



Gambar 4. 23 *Plot Aktual vs Prediksi Random Search CV 10*

Pada Gambar 4.23 *plot* aktual vs prediksi *Random Search CV 10*, menunjukkan peningkatan yang cukup jelas dibandingkan CV 5. Titik-titik prediksi terlihat lebih rapat dan lebih konsisten mengikuti garis ideal, terutama pada rentang harga rendah hingga menengah. Hal ini mengindikasikan bahwa penggunaan jumlah *fold* yang lebih besar membantu model dalam mempelajari pola data secara lebih menyeluruh.



Gambar 4. 24 *Residual Plot Random Search CV 10*

Gambar 4.24 *Residual plot* pada CV 10 memperlihatkan distribusi *residual* yang lebih seimbang di sekitar garis nol dibandingkan dengan CV 5. Pola kipas masih terlihat, namun intensitasnya relatif berkurang. Sebagian besar *residual* berada pada rentang yang lebih sempit, menunjukkan bahwa kesalahan prediksi menjadi lebih stabil. Dengan demikian, model *Random Search* CV 10 memiliki kemampuan generalisasi yang lebih baik dibandingkan CV 5, meskipun masih terdapat penyimpangan pada nilai harga yang sangat tinggi.

c. *Hyperparameter tuning dengan Bayesian Optimization*

Bayesian Optimization merupakan metode optimasi *hyperparameter* berbasis probabilistik yang secara adaptif memilih kombinasi parameter berdasarkan hasil evaluasi sebelumnya. Hasil dari *Bayesian Optimization* ditunjukkan pada Tabel 4.13


Tabel 4. 13 Hasil *Bayesian Optimization*

Metrik evaluasi	CV 3	CV 5	CV 10	AVG
R ² CV	0.7658	0.7619	0.7569	0.7615
MSE CV	4.750.360,76	4.829.285,09	4.929.881,44	4.836.509,10
RMSE CV	2.179,53	2.197,56	2.220,33	2.199,14
Waktu Training & Tuning	0:18	1:56	4:56	2:23
Ukuran Model	313,18 KB	323,16 KB	316,34 KB	-
R ² Tes	0.6943	0.7020	0.7107	0.7023
MSE Tes	4.697.779,12	4.579.233,46	4.446.461,11	4.574.491,23
RMSE Tes	2.167,44	2.139,91	2.108,66	2.138,67
Best params	kernel: rbf, C: 3, epsilon: 0.04, gamma: scale	kernel: rbf, C: 5, epsilon: 0.03, gamma: scale	kernel: rbf, C: 10, epsilon: 0.035, gamma: scale	-

Berdasarkan hasil pada Tabel 4.13, *Bayesian Optimization* menunjukkan pola peningkatan performa yang lebih bertahap seiring bertambahnya *cross-validation*. Pada CV 3, model sudah mampu mempelajari pola umum data, namun performanya pada data uji belum stabil. Pada CV 5 dan CV 10, performa pada data uji menjadi lebih konsisten, yang menunjukkan bahwa model memperoleh estimasi parameter yang lebih representatif dari distribusi data.


Karakteristik ini sesuai dengan prinsip *Bayesian Optimization* yang melakukan pencarian parameter secara adaptif berdasarkan hasil evaluasi sebelumnya. Hasil ini sesuai dengan penelitian T. V. Saradhi [12] dan C. M. Liyew et al. [13] yang menyatakan *Bayesian Optimization* mampu menghasilkan performa yang stabil melalui pendekatan pencarian berbasis probabilistik. Dengan bertambahnya jumlah *fold*, proses evaluasi menjadi lebih informatif sehingga pemilihan *hyperparameter* menjadi lebih tepat. Hal ini relevan dengan data harga rumah di Kota Bandung yang memiliki variasi cukup lebar, terutama pada harga menengah hingga tinggi, sehingga membutuhkan proses optimasi yang mempertimbangkan distribusi data secara lebih menyeluruh.

Namun, berbeda dengan penelitian tersebut yang menunjukkan keunggulan *Bayesian Optimization* sebagai metode terbaik, pada penelitian ini performanya masih berada pada kisaran yang sangat dekat dengan *Random Search*. Hal ini menunjukkan bahwa pada kasus prediksi harga rumah dengan *SVR*, keunggulan *Bayesian Optimization* tidak selalu signifikan dan sangat dipegaruhi oleh karakteristik data serta ruang parameter yang digunakan. Berikut adalah hasil visualisasi *plot* aktual vs prediksi dan *plot residual Bayesian Optimization*:




Gambar 4. 25 *Plot Aktual vs Prediksi Bayesian Optimization CV 3*

Pada skema *Bayesian Optimization CV 3*, Gambar 4.25 *plot* aktual vs prediksi menunjukkan bahwa model mampu mengikuti tren umum hubungan antara harga aktual dan prediksi. Namun, sebaran titik masih terlihat cukup lebar, khususnya pada harga menengah hingga tinggi. Beberapa titik prediksi berada cukup jauh dari garis ideal, yang mengindikasikan adanya kesalahan prediksi yang relatif besar pada sebagian data uji.




Gambar 4. 26 *Residual Plot Bayesian Optimization CV 3*

Gambar 4.26 *residual plot* pada CV 3 memperlihatkan pola *residual* yang belum sepenuhnya acak, dengan variansi *residual* yang meningkat pada nilai prediksi yang lebih besar. Selain itu, terdapat beberapa *residual* ekstrem yang cukup jauh dari garis nol. Hal ini menunjukkan bahwa meskipun *Bayesian Optimization* efektif dalam mencari kombinasi *hyperparameter* yang baik, penggunaan jumlah *fold* yang relatif kecil menyebabkan model belum sepenuhnya stabil dalam meminimalkan kesalahan prediksi.




Gambar 4. 27 *Plot* Aktual vs Prediksi *Bayesian Optimization* CV 5

Pada Gambar 4.27 *plot* aktual vs prediksi *Bayesian Optimization* CV 5 menunjukkan bahwa sebagian besar titik prediksi mengikuti arah garis ideal, khususnya pada rentang harga rumah rendah hingga menengah. Hal ini mengindikasikan bahwa model telah mampu menangkap pola umum hubungan antara nilai aktual dan nilai prediksi. Namun, pada harga rumah yang lebih tinggi, sebaran titik terlihat semakin melebar dan menjauh dari garis diagonal, menandakan bahwa akurasi prediksi menurun pada segmen harga tersebut.




Gambar 4. 28 *Residual Plot Bayesian Optimization CV 5*

Pada Gambar 4.28 *residual plot* pada CV 5 menunjukkan bahwa *residual* masih belum terdistribusi secara acak di sekitar garis nol. Terlihat adanya pola kipas, di mana variansi *residual* meningkat seiring dengan bertambahnya nilai prediksi. Selain itu, terdapat beberapa *residual* ekstrem dengan nilai negatif yang cukup besar, yang menunjukkan kecenderungan model untuk melakukan *overestimation* atau *underestimation* pada harga rumah bernilai tinggi. Kondisi ini mengindikasikan bahwa stabilitas kesalahan prediksi masih perlu ditingkatkan.



Gambar 4. 29 *Plot Aktual vs Prediksi Bayesian Optimization CV 10*

Pada Gambar 4.29 skema *Bayesian Optimization CV 10*, *plot* aktual vs prediksi menunjukkan peningkatan konsistensi dibandingkan CV 5. Titik-titik prediksi terlihat lebih rapat dan lebih sejajar dengan garis ideal, terutama pada rentang harga rendah hingga menengah. Hal ini menunjukkan bahwa peningkatan jumlah *fold* pada proses validasi silang membantu model dalam mempelajari karakteristik data secara lebih menyeluruh.



Gambar 4. 30 *Residual Plot Bayesian Optimization CV 10*

Pada Gambar 4.30 *residual plot* pada CV 10 memperlihatkan distribusi *residual* yang lebih seimbang di sekitar garis nol dibandingkan CV 5. Pola kipas masih terlihat, namun dengan intensitas yang lebih rendah. Sebagian besar *residual* berada dalam rentang yang lebih sempit, yang menandakan bahwa kesalahan prediksi menjadi lebih stabil. Meskipun masih terdapat beberapa *residual* ekstrem pada nilai prediksi yang tinggi, secara keseluruhan model dengan CV 10 menunjukkan kemampuan generalisasi yang lebih baik dibandingkan CV 5.

4.9 Evaluasi Data Eksternal

Evaluasi data eksternal dilakukan untuk menguji kemampuan generalisasi model dalam memprediksi harga rumah pada data di luar dataset pelatihan. Pengujian eksternal ini bertujuan untuk mengetahui sejauh mana model yang telah dibangun mampu mempertahankan performanya ketika diterapkan pada data nyata

(*real-world data*) yang tidak terlibat sama sekali dalam proses pelatihan maupun optimasi model.

Data eksternal pada penelitian ini diperoleh secara mandiri melalui pengumpulan data dari situs properti rumah123.com. Pengumpulan data dilakukan secara manual dengan cara memasukkan data satu per satu berdasarkan informasi properti yang tersedia pada situs tersebut. Proses pengambilan data dilakukan pada periode November hingga Desember 2025, yang ditunjukkan pada fitur tanggal pembaruan data properti. Dataset ini dapat diakses pada tautan berikut <https://github.com/Ulfa32/house-price-app>. Dataset terdiri dari 30 data properti dengan 6 fitur. Deskripsi data eksternal disajikan pada Tabel 4.14 di bawah ini:

Tabel 4. 14 Deskripsi Data Eksternal

Fitur	Keterangan	Tipe Data
Harga	Harga properti dalam Rupiah Indonesia	<i>String</i>
Jumlah Kamar Tidur	Jumlah kamar tidur di properti	<i>Integer</i>
Jumlah Kamar Mandi	Jumlah kamar mandi di properti	<i>Integer</i>
Luas Tanah	Luas total tanah properti dalam meter persegi	<i>Integer</i>
Luas Bangunan	Luas total bangunan properti dalam meter persegi	<i>Integer</i>
Lokasi	Lokasi atau area di Bandung tempat properti tersebut berada	<i>String</i>
Diperbarui	Tanggal data properti yang diperbarui	<i>String</i>

Data uji eksternal yang digunakan pada penelitian ini memiliki karakteristik yang berbeda secara nyata dibandingkan data latih dan uji internal. Perbedaan utama terlihat pada rentang harga yang lebih lebar, variasi lokasi yang tidak merata, serta adanya beberapa kecamatan yang belum pernah muncul pada data latih. Kondisi ini mencerminkan situasi pasar yang lebih realistis, data diperoleh dari periode berbeda, serta dipengaruhi oleh faktor eksternal seperti kenaikan harga properti dan dinamika pasar perumahan Kota Bandung.

Fitur yang digunakan pada data eksternal disesuaikan dengan fitur yang digunakan pada tahap pemodelan, yaitu harga rumah, jumlah kamar tidur, jumlah kamar mandi, luas tanah, luas bangunan, serta lokasi properti. Dengan kesesuaian fitur tersebut, data eksternal dapat diproses menggunakan tahapan *preprocessing* dan fitur *engineering* yang sama dengan data utama, sehingga pengujian dapat dilakukan secara konsisten dan adil. *Sample* dataset uji eksternal disajikan pada Tabel 4.15 berikut:

Tabel 4. 15 *Sample* Data Uji Eksternal

Harga	KT	KM	LT	LB	Lokasi	Diperbarui
19,5 miliar	5	5	822	927	Sukajadi	7/11/2025
2,2 miliar	5	3	174	300	Lengkong	7/11/2025
5 miliar	5	3	463	500	Buah Batu	7/11/2025
3,35 miliar	3	2	200	130	Bojongloa Kidul	7/11/2025
2.9 miliar	5	3	280	220	Regol	7/11/2025

Setelah melalui *tahap preprocessing*, data eksternal digunakan sebagai data uji tambahan untuk mengevaluasi beberapa model *SVR*, yaitu *Baseline* serta model hasil optimasi *hyperparameter* menggunakan *Grid Search*, *Random Search*, dan *Bayesian Optimization*. Evaluasi dilakukan menggunakan metrik R^2 , MSE, dan RMSE. Hasil pengujian model menggunakan data eksternal ditunjukkan pada Tabel 4.16 berikut

Tabel 4. 16 Hasil Evaluasi Data Eksternal

Metode	R ²	MSE	RMSE
RS CV 3	0.4529	31.177.476,78	5.583,68
BO CV 5	0.4520	31.232.740,08	5.588,63
BO CV 3	0.4483	31.440.535,84	5.607,19
GS CV 3	0.4483	31.440.535,84	5.607,19
RS CV 10	0.4439	31.692.951,94	5.629,65
GS CV 5	0.4406	31.878.910,98	5.646,14
RS CV 5	0.4406	31.878.910,98	5.646,14
GS CV 10	0.4372	32.073.838,31	5.663,38
BO CV 10	0.4320	32.373.187,54	5.689,74
<i>Baseline</i>	0.4071	33.788.398,32	5.812,78

Berdasarkan hasil pengujian pada data eksternal, terlihat seluruh model hasil optimasi *hyperparameter* menunjukkan peningkatan performa dibandingkan dengan model *baseline*. Hal ini ditunjukkan oleh peningkatan R² dari *baseline* yaitu 0.4071 menjadi kisaran 0.43 sampai 0.45 pada model hasil tuning, serta penurunan RMSE dari 5.812,78 menjadi sekitar 5.583 sampai 5.689.

Model dengan performa terbaik pada data uji eksternal adalah *Random Search* dengan CV 3, yang menghasilkan nilai R² sebesar 0.4529, MSE sebesar 31.117.476,78, dan RMSE sebesar 5.583,68. Dibandingkan *baseline*, nilai RMSE pada model ini turun sekitar 229 ribu rupiah per rumah, yang menunjukkan peningkatan akurasi prediksi pada data nyata.

Perbedaan performa antar metode tuning relatif kecil, selisih RMSE antara model terbaik *Random Search* CV 3 dan model lainnya berada pada rentang kurang 110 ribu rupiah, sehingga secara praktis perbedaannya tidak terlalu

signifikan dalam konteks harga rumah di Kota Bandung yang berada pada kisaran ratusan juta hingga miliaran rupiah. Hal ini menunjukkan bahwa seluruh metode tuning menghasilkan model dengan tingkat generalisasi yang hampir setara pada data eksternal.

Selain itu, nilai R^2 yang cenderung menurun dibandingkan pengujian internal mengindikasikan bahwa data eksternal memiliki variansi yang lebih tinggi dan karakteristik yang berbeda. Namun, model hasil *Random Search* tetap mampu mempertahankan nilai R^2 tertinggi secara konsisten pada data eksternal, yang menunjukkan stabilitas generalisasi yang lebih baik dibandingkan *Grid Search* dan *Bayesian Optimization*. Secara keseluruhan, hasil ini menunjukkan bahwa *Random Search* menghasilkan model *SVR* yang paling stabil pada pengujian data eksternal, dengan kesalahan prediksi terendah dan kemampuan menjelaskan variasi data yang lebih baik, meskipun selisih performanya dengan metode lain tidak terlalu jauh.

4.10 Komparasi Model

Sub bab ini membahas perbandingan kinerja seluruh model yang dibangun dalam penelitian, meliputi model *Baseline Support Vector Regression*, model hasil *hyperparameter tuning*, serta pengujian pada data uji eksternal. Komparasi dilakukan berdasarkan aspek akurasi prediksi, kemampuan generalisasi, dan efisiensi komputasi, sehingga pemilihan model terbaik dapat dilakukan secara objektif dan menyeluruh.

a. Komparasi Model pada Data Latih

Evaluasi pada data latih bertujuan untuk menilai kemampuan masing-masing model dalam mempelajari pola hubungan antara fitur dan harga rumah. Selain metrik evaluasi, waktu komputasi juga dianalisis untuk melihat kompleksitas proses pelatihan model. Komparasi ditunjukkan pada Tabel 4.17 berikut

Tabel 4.17 Komparasi Model Data Latih terhadap *Baseline*

Model	Presentase Penurunan MSE	Presentase Penurunan RMSE	Selisih Peningkatan R²	Waktu Komputasi Train
<i>Grid Search</i> (AVG)	-76.50%	-51.52%	0.7699	5:07
<i>Random Search</i> (AVG)	-76.47%	-51.49%	0.7695	2:17
<i>Bayesian Optimization</i> (AVG)	-76.31%	-51.32%	0.7679	2:23

Berdasarkan Tabel 4.17 hasil komparasi pada data latih, terlihat bahwa *Grid Search* merupakan metode paling akurat dalam penelitian ini. Hal ini ditunjukkan oleh penurunan MSE dan RMSE terbesar serta peningkatan R² tertinggi dibandingkan metode lainnya. Meskipun selisih akurasi dengan *Random Search* dan *Bayesian Optimization* relatif kecil, *Grid Search* tetap unggul secara konsisten pada seluruh metrik evaluasi. Oleh karena itu, *Grid Search* dapat ditetapkan sebagai *best method* dari sisi akurasi prediksi.

Namun, keunggulan akurasi *Grid Search* disertai waktu komputasi yang paling lama. Sebaliknya, *Random Search* merupakan metode yang paling cepat, dengan waktu pelatihan kurang dari setengah waktu pada *Grid Search*, tetapi tetap mampu mempertahankan penurunan *error* di atas 76% dan penurunan RMSE sekitar 51%. Selisih *error* prediksi antara *Random Search* dan *Grid Search* hanya berada pada kisaran puluhan ribu rupiah, sehingga perbedaannya tidak terlalu signifikan dalam konteks harga rumah di Kota Bandung.

Sementara itu, *Bayesian Optimization* menempati posisi paling seimbang. Metode ini tidak secepat *Random Search*, tetapi tetap jauh lebih efisien dibandingkan dengan *Grid Search*, dengan performa akurasi yang sangat mendekati metode terbaik. Karakteristik ini menunjukkan bahwa *Bayesian Optimization* efektif dalam mengarahkan pencarian *hyperparameter* ke area yang optimal tanpa eksplorasi berlebihan.

Ketiga metode ini sama-sama memberikan penurunan *error* prediksi dari sekitar Rp. 4,5 juta menjadi kurang lebih Rp. 2,2 juta, atau berkurang sekitar Rp. 2,3 juta per rumah. Dalam konteks harga rumah yang umumnya berada pada kisaran ratusan juta hingga miliaran rupiah, penurunan *error* ini dapat dianggap cukup signifikan. Dapat dilihat bahwa *Grid Search* adalah metode yang paling akurat, *Random Search* adalah metode paling cepat, dan *Bayesian Optimization* merupakan metode dengan keseimbangan terbaik antara akurasi dan efisiensi.

b. Komparasi Model pada Data Uji Internal

Evaluasi pada data uji internal digunakan untuk menilai kemampuan generalisasi model terhadap data yang tidak digunakan dalam proses pelatihan. Untuk menghindari bias akibat variasi *cross-validation*, digunakan nilai rata-rata performa data uji dari masing-masing metode. Komparasi ditunjukkan pada Tabel 4.18

Tabel 4. 18 Komparasi Model Data Uji Internal terhadap *Baseline*

Model	Penurunan MSE	Penurunan RMSE	Selisih Peningkatan R ²
<i>Grid Search</i> (AVG)	-69.36%	-44.66%	0.6961
<i>Random Search</i> (AVG)	-69.54%	-44.80%	0.6978

Model	Penurunan MSE	Penurunan RMSE	Selisih Peningkatan R^2
<i>Bayesian Optimization</i> (AVG)	-69.47%	-44.77%	0.6971

Hasil evaluasi pada data uji internal pada Tabel 4.18 menunjukkan bahwa seluruh metode *hyperparameter tuning* meningkatkan performa yang sangat signifikan dibandingkan *Baseline*. Penurunan nilai MSE berada pada kisaran 69% yang menandakan bahwa sebagian besar kesalahan prediksi pada model awal berhasil dikurangi setelah proses tuning. Hal ini menunjukkan bahwa model *Baseline* belum mampu menangkap hubungan kompleks antara fitur rumah dan harga, sementara model yang telah dituning lebih adaptif terhadap pola data.

Dari sisi RMSE, terjadi penurunan *error* sekitar 44-45% yaitu dari kisaran Rp. 3,87 juta menjadi sekitar Rp. 1,7 juta per rumah. Dalam konteks harga rumah di Kota Bandung yang umumnya berada pada rentang harga ratusan juta hingga miliaran rupiah, penurunan *error* ini cukup relevan untuk meningkatkan estimasi harga.

Jika dibandingkan antar metode, *Random Search* menghasilkan performa terbaik pada data uji internal, ditunjukkan oleh penurunan MSE dan RMSE paling besar serta nilai R^2 tertinggi yaitu 0.6978. Namun, keunggulan *Random Search* terhadap *Grid Search* dan *Bayesian Optimization* relatif berdekatan, dengan selisih *error* yang berada pada kisaran puluhan ribu rupiah. Perbedaan ini menunjukkan bahwa ketiga metode memiliki kemampuan generalisasi yang hampir setara pada data uji internal.

Secara keseluruhan, hasil ini menegaskan bahwa seluruh metode tuning efektif dalam meningkatkan performa *SVR*, dengan *Random Search* sebagai metode yang paling unggul pada data uji internal, sementara *Grid*

Search dan *Bayesian Optimization* tetap memberikan performa yang sangat kompetitif.

c. Komparasi Model pada Data Uji Eksternal

Pengujian pada data uji eksternal dilakukan menggunakan 30 data properti yang dikumpulkan secara manual dari situs rumah123.com pada periode November-Desember 2025. Pengujian ini bertujuan untuk menguji kemampuan generalisasi model pada data dunia nyata. Hasil komparasi ditunjukkan pada Tabel 4.19

Tabel 4. 19 Komparasi Model Data Uji Eksternal

Model	MSE	RMSE	R ²
<i>Baseline</i>	33.788.398,32	5.812,78	0.4071
<i>Grid Search</i> (AVG)	31.797.761,71	5.638,90	0.4420
<i>Random Search</i> (AVG)	31.583.113,23	5.619,82	0.4458
<i>Bayesian Optimization</i> (AVG)	31.682.154,49	5.628,52	0.4441

Berdasarkan Tabel 4.19 pengujian pada data uji eksternal menunjukkan bahwa seluruh model mengalami penurunan performa dibandingkan dengan pengujian internal. Hal ini terlihat dari nilai RMSE yang meningkat dan nilai R² yang menurun pada semua model. Kondisi ini terjadi karena data uji eksternal berasal dari periode yang berbeda dengan data pelatihan, sehingga memiliki distribusi fitur dan rentang harga yang tidak sepenuhnya sama dengan data latih. Perbedaan ini membuat model diuji pada variasi kasus yang belum sepenuhnya dipelajari sebelumnya. Model *baseline* kembali menunjukkan performa terendah dengan RMSE sebesar 5.812,78 dan R² sebesar 0.4071.

Meskipun demikian, model hasil *hyperparameter tuning* tetap memberikan peningkatan performa dibandingkan *baseline*. *Random Search* menghasilkan performa terbaik pada data uji eksternal dengan nilai MSE

sebesar 31.583.113,23, RMSE sebesar 5.619,82, dan R^2 sebesar 0.4458. *Grid Search* dan *Bayesian Optimization* menunjukkan performa yang sangat berdekatan, dengan selisih nilai R^2 dan *error* yang relatif kecil.

Secara keseluruhan, hasil ini menunjukkan bahwa Random Search memiliki kemampuan generalisasi yang paling stabil pada data uji eksternal. Meskipun peningkatan akurasi tidak terlalu besar, model ini tetap konsisten memberikan *error* prediksi yang lebih rendah dibandingkan metode lainnya, sehingga lebih bagus ketika diterapkan pada data harga rumah di luar data pelatihan.

Secara keseluruhan, hasil komparasi menunjukkan bahwa *hyperparameter tuning* meningkatkan kinerja model *SVR* dibandingkan model *baseline*, baik pada data latih, data uji internal, maupun data uji eksternal. Peningkatan ini ditunjukkan oleh penurunan nilai *error* prediksi serta peningkatan nilai R^2 . Temuan ini menguatkan penelitian T. V. Saradhi [12] yang menegaskan bahwa *hyperparameter tuning* berperan penting dalam meningkatkan performa model berbasis *Support Vector*. Perbedaannya, penelitian ini tidak hanya fokus pada peningkatan akurasi, tetapi juga mengevaluasi stabilitas performa dan efisiensi komputasi pada kasus prediksi harga rumah yang memiliki variasi data cukup tinggi.

Hasil penelitian menunjukkan bahwa *Grid Search* mampu menghasilkan tingkat akurasi yang tinggi, khususnya pada tahap pelatihan. Temuan ini sejalan dengan penelitian Mulyawan et al [10] yang menyatakan bahwa *penerapan Grid Search* pada model *SVR* dapat meningkatkan performa prediksi harga rumah dibandingkan penggunaan parameter *default*. Namun, pada penelitian ini keunggulan *Grid Search* lebih dominan dari sisi akurasi, sementara kebutuhan waktu komputasi relatif lebih besar akibat evaluasi kombinasi parameter yang bersifat menyeluruh, sehingga kurang efisien ketika diterapkan pada keterbatasan sumber daya komputasi.

Random Search menunjukkan performa yang paling stabil pada data uji internal dan data uji eksternal. Pada pengujian data eksternal, *Random Search* menghasilkan R^2 dengan nilai 0.4458, yang merupakan capaian terbaik

dibandingkan metode tuning lainnya pada skenario ini. Hasil tersebut menunjukkan bahwa *Random Search* memiliki kemampuan generalisasi yang lebih baik ketika dihadapkan pada data dengan distribusi yang berbeda dari data latih. Temuan ini mendukung penelitian F. W. Hartono et al [8] yang menyatakan bahwa *Random Search* efektif dalam menemukan kombinasi *hyperparameter* yang baik secara efisien, sekaligus memperkuat bukti bahwa metode ini cocok diterapkan pada data harga rumah.

Sementara itu, *Bayesian Optimization* dalam penelitian ini menunjukkan kinerja yang seimbang antara akurasi dan efisiensi komputasi. Temuan ini sejalan dengan penelitian T. V. Saradhi [12] dan C. M. Liyew et al. [13] yang menyatakan bahwa *Bayesian Optimization* mampu mengarahkan proses pencarian *hyperparameter* secara lebih terfokus. Namun, berbeda dengan beberapa penelitian terdahulu yang menempatkan *Bayesian Optimization* sebagai metode paling unggul, penelitian ini menemukan bahwa *Random Search* memberikan hasil yang lebih konsisten pada data uji internal dan eksternal. Oleh karena itu, *Random Search* dapat ditetapkan sebagai metode yang paling optimal dalam penelitian ini, karena mampu memberikan keseimbangan terbaik antara akurasi, stabilitas generalisasi, dan efisiensi komputasi pada prediksi harga rumah di Kota Bandung.

4.11 *Deployment*

Tahap *Deployment* dilakukan untuk mengimplementasikan model prediksi harga rumah yang telah dikembangkan ke dalam sebuah *website* yang dapat digunakan secara langsung. *Repository* pada penelitian ini dapat diakses melalui tautan berikut: <https://github.com/Ulfa32/house-price-app>. Seluruh model hasil pemodelan, yaitu *Baseline SVR*, *Grid Search*, *Random Search*, dan *Bayesian Optimization*, *dideploy* menggunakan *streamlit* sehingga proses prediksi dapat dilakukan secara interaktif melalui antarmuka *website* yang dapat diakses melalui tautan berikut: <https://house-price-app-in-bandung-city.streamlit.app>

Input yang diberikan oleh pengguna meliputi spesifikasi rumah seperti luas bangunan, luas tanah, jumlah kamar tidur, jumlah kamar mandi, serta lokasi kecamatan di Kota Bandung. Pengguna juga dapat memilih model *SVR* yang akan

digunakan. Dengan demikian, *website* tidak hanya berfungsi sebagai alat prediksi, tetapi juga sebagai sarana untuk membandingkan hasil prediksi antar model secara langsung pada data yang sama.

Hasil prediksi ditampilkan dalam satuan rupiah, sehingga mudah dipahami. Secara keseluruhan, tahap *deployment* membuktikan bahwa pendekatan *SVR* dengan berbagai metode *hyperparameter tuning* dapat diimplementasikan dalam sistem nyata, serta mendukung tujuan penelitian untuk menghasilkan model prediksi harga rumah yang aplikatif dan mudah diakses oleh pengguna. *Input user* ditunjukkan pada Gambar 4.31

Prediksi Harga Rumah Kota Bandung

Masukkan spesifikasi rumah, pilih kecamatan dan model, lalu prediksi harga.

Spesifikasi Rumah

Jumlah Kamar Tidur

0

Jumlah Kamar Mandi

0

Luas Bangunan (m²)

contoh: 120

Luas Tanah (m²)

contoh: 150

Kecamatan

Pilih Kecamatan

Pilih Model

Metode Pemodelan

Pilih Model

Prediksi Harga

Gambar 4. 31 *Input User*